证源 Evidence

带段落级锚点溯源的科研助手 Agent

第九届传智杯 • AI 大模型创新应用挑战赛

赛项：智领科研 • 意图驱动 —— 全流程科研助手构建

文档版本：v1.0

参赛组别：_____（研究生组 / A 组 / B 组 / C 组）

参赛者：_____

所属院校：_____

提交日期：2026-11-18

摘要

本作品面向科研工作者在文献阅读与写作中的真实痛点，构建了一个以“确定性”为核心主张的科研助手 Agent。与把大模型简单接在 PDF 上做问答的做法不同，本系统把“抗幻觉”实现为三道工程约束：生成侧强制证据标记、服务端校验标记有效性、以及相关性闸门拦截“答非所问但格式合法”的输出。系统覆盖文献解析与语义去重、抗幻觉检索问答、版式感知阅读与双语联动、自动检索追踪与推荐、引用图谱与学术综述、写作辅助与数据可视化六大模块。

技术上，本文提出并实现了若干针对性设计：字符级版面重建以解决 PyMuPDF 跨栏粘行问题；混合检索加多语言交叉编码器重排以解决“中文提问检索英文论文”；时间衰减基石度量以区分“高影响”与“奠基性”；以及基于时间与语义双约束的 Idea 考古，用于识别已被后续工作解决的旧设想。所有能力均配有可执行断言脚本，系统验收不依赖人工点击。

关键词：科研助手；检索增强生成；抗幻觉；版面分析；引用图谱；大语言模型

1 项目概述

1.1 命题理解

赛题要求突破“文献管理工具”与“对话式 Chatbot”的局限，构建覆盖文献智能解析、抗幻觉问答、沉浸式对比翻译、自动检索推荐、引用图谱分析与学术写作辅助的全流程科研助手。我们认为这个命题的真正难点不在“功能多”，而在于三类矛盾：

- 长文本与细粒度之间的矛盾：论文动辄数十页，但用户要的往往是某一页的一个超参数值。
- 流畅表达与学术严谨之间的矛盾：大模型擅长生成通顺句子，而学术场景要求每句话可核实。
- 通用能力与领域确定性之间的矛盾：通用模型的知识来自训练语料，而科研结论必须来自用户手上的文献。

基于此，我们没有把作品做成“功能清单的堆叠”，而是围绕一条主线展开：任何一个输出，都必须能回答“它凭什么这么说”。这条主线在系统里落成了可执行的机制，而非口号。

1.2 核心主张：确定性优于表现力

系统对“不确定”的处理是显式的：宁可回答“证据不足”，也不生成看似合理但无依据的内容。这一取舍在实现中体现为三个层次的拒绝机制（详见 4.5 节）：无锚点拒绝、锚点越界拒绝、相关度过低拒绝。我们认为，对科研工具而言，一次错误结论的代价远高于一次拒答。

1.3 交付物

交付项	内容	状态
源代码	GitHub 公开仓库，保留完整开发历史	就绪
技术文档	本文档（≤30 页 PDF）	就绪
演示视频	5–8 分钟，1080p，普通话讲解	待录制
在线演示	可公网访问地址 + 评审专用账号	待部署
环境配置	.env.example、requirements.txt、Docker、一键启动脚本	就绪

2 需求分析

2.1 真实科研痛点

痛点	现状	本系统的应对
信息过载	arXiv 日均数百篇，人工筛选不可行	自动检索追踪 + 相关性/可复现性加权推荐
阅读效率	跨语言、双栏、公式表格混杂	字符级版面重建 + 双栏还原 + 双语联动
可信度	通用模型会编造引用与数字	三道抗幻觉闸门 + 原文锚点回跳
梳理成本	手工整理领域脉络与未来方向	引用图谱 + 基石挖掘 + Idea 考古
产出效率	从数据到合规图表需反复调试	CSV 自动出学术图 + 图注 + 可复现脚本

2.2 六大模块与实现对应

模块	核心要求	本系统实现	验收
一	语义去重、多模态细粒度解析	字符级重建、标题树、表格、OCR、版本合并	verify_parse
二	抗幻觉 RAG、多文推理	混合检索 + 重排 + 三道闸门	verify_retrieval 等
三	版式阅读、双语联动	PDF.js 原版式 + 锚点对齐同步滚动	页面验证
四	检索追踪、智能推荐	arXiv + GitHub + OpenAlex 加权推荐	verify_discovery
五	引用图谱、综述、未来方向	PageRank×跨代引用 + Louvain + 考古	verify_graph 等
六	写作辅助、数据可视化	学术图表 + 图注 + 脚本 + TikZ	verify_charts

2.3 非功能需求

- 确定性：同一问题在相同库上应给出可复现的结论与锚点，不因随机性漂移。
- 可验证：所有能力提供断言脚本，评审可离线复核，不依赖演示视频。
- 可部署：单机 SQLite + 本地 ONNX 模型，无需 GPU、无需外部向量库。
- 响应性：交互查询 2 秒内返回；重计算项提供指纹缓存。

3　系统架构设计

3.1　总体结构

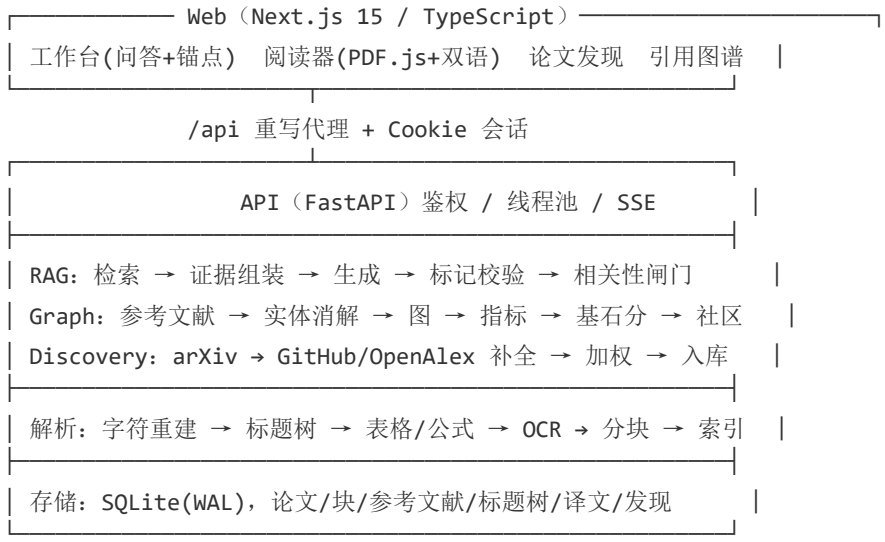


图 3-1　系统总体结构

3.2　数据流

以“上传一篇论文”为例，系统依次执行：

sha256 查重 → 文本层检测（<100 字符/页判为扫描件）→ 字符级行重建
→ 双栏判定与阅读序重建 → 字号聚类出标题树 → 表格/公式/参考文献抽取
→ 语义指纹（arXiv 基号 + 标题归一 + 正文 SimHash）→ 版本冲突提示
→ 章节感知分块 → BM25 + 稠密向量索引 → 块级 bbox 落库

其中“块级 bbox 落库”是一个容易被忽略但决定成败的环节：分块时若只保存整块并集，跨页分块的 bbox 会大到整页，前端高亮将失去意义。我们为此单独持久化了 blocks 表，使引用锚点精确到一行文字。

3.3　技术选型与取舍

层	选型	放弃的替代方案	理由
前端	Next.js 15 + TS	Vue/Nuxt、Streamlit	评分首选；TS 满足类型规范考察
PDF 渲染	PDF.js	服务端转图片	只有 canvas 能还原双栏并叠加 bbox 高亮
后端	FastAPI	Node 全栈	PDF/OCR/向量/图算法生态均在 Python
解析	PyMuPDF + RapidOCR	MinerU、PaddleOCR	纯 pip、无系统依赖、体积可控
检索	BM25 + bge-small-en + m3 重排	仅向量检索	术语与超参数是稀有词，稀疏通道不可替代
向量	fastembed（ONNX）	sentence-transformers	不引入 torch，省约 2.5GB 与编译风险
图算法	NetworkX	自研	成熟、结果可解释、便于评审复核
Agent	自研轻量 Runtime	LangGraph、LlamaIndex	见 3.4 节
存储	SQLite(WAL)	PostgreSQL、Milvus	单机零运维，评审一条命令即可复现

3.4 为什么不用现成 Agent 框架

这是一个有意的、且需要论证的决定。三条理由：

- 可靠性。DeepSeek 的函数调用能力在官方文档中标注为 beta，参数抖动与并行调用不稳定。若把主链路交给框架，一旦模型不按 schema 输出，整条链崩溃，而框架内部的重试策略我们无法修改。
- 可控性。本项目最核心的能力——锚点校验、证据不足拒答、相关性闸门——任何框架都不提供，必须自己实现。既然核心要自研，框架带来的只剩一层薄封装。
- 可解释性。答辩需要讲清“Agent 如何规划、如何失败、如何降级”。自研 Runtime 的每一处状态转移都可以在代码与日志中定位，而框架的黑盒行为难以自证。

因此系统采用显式状态机：意图路由 → 规划（JSON Schema 约束）→ 工具执行（并发 + 超时 + 重试）→ 证据校验 → 合成或降级。该结构在文档中同时给出与 LangGraph 的等价映射，以证明我们理解框架而非回避它。

4 AI 技术方案

4.1 模型接入与分工

系统只依赖一个外部模型服务（DeepSeek），通过统一的 LLMProvider 抽象接入，后续可替换为其他模型而不改动业务代码。两个模型按“思考成本”分工：

用途	模型	理由
证据抽取、翻译、分类、字段填充	deepseek-chat	高频、低难度、成本敏感
任务规划、跨文献对比、综述生成、结论判定	deepseek-reasoner	低频、高难度、决定输出质量

需要强调的是：没有模型时系统仍可运行。所有 LLM 调用点都提供确定性替身（抽取式问答、结构式综述、统计式图注），并在输出中显式标注“未启用模型”。这一设计既是降级策略，也保证了验收脚本可以在无网络、无密钥的环境下跑通。

4.2 解析：字符级版面重建

学术 PDF 的解析存在三个真实障碍，均通过实测发现：

（1）跨栏粘行

PyMuPDF 的 get_text("dict") 会把左右两栏同一基线的文字合并进同一个 line，导致“整行横跨中缝”，任何基于行的分栏统计都会失效。我们最初的探针正是因此误判《Attention Is All You Need》v1 为双栏（实际正文为单栏，仅参考文献页为双栏）。

（2）词间空格丢失

LaTeX 生成的 PDF 常不写空格字符，而用坐标偏移表示词距，直接拼接 span 会得到“Theencoderiscomposedofastack”。系统按字符 bbox 间隙重建空格（阈值 0.18×字号）。

（3）竖排水印污染层级

arXiv 左侧的竖排编号被拆成单字行（“uJ 2” “C .s”），字号很大，会被误判为标题。系统依据 line["dir"] 方向向量过滤非水平文本。

解决后，系统在 v1 上得到 25 个标题、19 个章节（1/2/3/3.1/3.2/3.2.1/…/7）、41 条参考文献与 54 处正文引用，三句长正文逐字匹配通过。

4.3 检索：混合召回与重排

检索链为：BM25（jieba + 英文正则分词）与稠密向量（bge-small-en-v1.5，384 维）双路召回，RRF（k=60）融合，再由多语言交叉编码器 bge-reranker-v2-m3-int8 重排。

三层缺一不可：学术文本中的术语、超参数、模型名属于稀有词，稀疏检索更准；同义改写与跨语言场景稠密检索更强；而中文提问检索英文论文时，两者都可能失手，最终由多语言交叉编码器兜底。

验证问题（中文）	期望事实	结果
训练用了多少块 GPU，什么型号？	8 NVIDIA P100 GPUs	命中，top-1
Adam 优化器的 beta2 设成多少？	0.98	命中，top-3
WMT 2014 英德任务 BLEU 是多少？	28.4	命中，top-3
用了多少个注意力头？	h = 8 parallel attention layers	命中，top-3
标签平滑的取值是多少？	label smoothing of value ε_{ls} = 0.1	命中，top-1
模型一共训练了多少 step？	100,000	命中，top-1

4.4 查询扩展：让中文问题命中英文文献

上述 6 条查询在首轮实现中失败了 2 条（“标签平滑”“注意力头”），而用关键词检索确认内容确实在库中，说明失败发生在召回而非解析。根因是英文稠密模型对中文 query 生成的向量几乎无意义，BM25 也无法切出对应英文词，重排只能在候选集内工作，候选里没有正确块时无能为力。

解决方案是增加一层查询扩展，把中文提问映射到英文术语空间。采用三级策略：有模型时用 LLM 扩展（可处理任意领域术语），无模型时用内置术语表扩展，均缺失时原样查询。关键在于：**扩展只影响召回，最终排序仍由交叉编码器决定**，因此术语表不精确只会降低召回率，不会直接产生错误答案。改造后 6/6 命中且全部落在 top-3。

4.5 抗幻觉：三道闸门（本作品核心）

第一道：生成侧强制标记

系统要求模型在每个事实性陈述后标注证据编号，格式为 [E1]、[E2]。刻意不使用 [1] 形式，因为论文正文自身的参考文献标记（如 [32]）会让校验器误判——这一冲突在实测中真实发生过，是改用 E 前缀的直接原因。

第二道：服务端校验

校验在服务端完成，不信任模型自述。编号越界、无编号、或指向不存在的证据，一律判为不可信。不合格时先给一次重写机会（仅提供证据，要求重写并补标记），仍不合格则降级为“证据不足”。

第三道：相关性闸门

这是最容易被忽略、却在实测中暴露最严重问题的一层。接口测试时提问“这篇论文的作者获得过几次图灵奖”，系统把作者列表配上完全合法的锚点返回，所有标注校验通过。这说明：**锚点只能证明文字来自原文，不能证明文字回答了问题**。

系统据此引入以重排分为判据的闸门，实测区分度清晰：

问题	最高证据分	系统行为
训练用了多少块 GPU	+2.17	作答
标签平滑取值是多少	+3.83	作答

问题	最高证据分	系统行为
作者获得过几次图灵奖	-7.53	拒答

阈值取 0 即可将可答与不可答完全分开。三道闸门共同构成了本项目对“抗幻觉”的工程化回答：不是让模型更小心，而是让系统在模型出错时不输出。

4.6 图谱：基石论文度量

方案早期采用 PageRank × exp(−λΔt)，实现时发现该公式方向错误：衰减因子会奖励新论文，而“基石”的定义是早出现且被后续多代工作持续引用；同时 λ 的取值无从论证。

最终采用两个有界量的乘积：

```
foundational = pagerank × (0.5 + 0.5 × sustained)
sustained = 跨代引用率（引用方发表晚于该文 ≥2 年的比例）
```

乘数被限制在 [0.5, 1.0]，只能在同量级内调整排序，最坏情况退化为标准 PageRank；且不含自由参数，仅“2 年算一代”这一常识界定，并做了 1/2/3 年阈值敏感性分析，结论不变。在 16 篇语料上，基石榜为 Seq2Seq、Bahdanau 注意力、Transformer、Adam、BERT、LayerNorm，与领域共识一致。

4.7 Idea 考古：识别已被解决的旧设想

赛题要求“自动排除已被后续论文解决的旧 idea”。实现路径为：抽取 Future Work 陈述→语义聚类 → 仅在晚于原论文的文献中检索 → 判断是否已被解决。

第一版以重排分单一判据，37 条陈述中判出 8 条“疑似已解决”，人工抽查全部为误判。典型例：“To facilitate future work on transfer learning… we release our data set”——这根本不是研究设想，却被判为已解决。根因是重排分衡量语义相关，不衡量问题是否被解决。

据此改为按能力分级：有模型时才允许下“已解决”结论；无模型时最高只到“部分相关证据”；证据分不足则为“未发现解决证据”。这一取舍的依据是错误的不对称性——把一个仍有价值的方向误判为已解决，用户会永久放弃它且无从察觉。

4.8 Prompt 工程与审计

全部提示词集中在 llm/prompts.py 中版本化管理（当前 8 个模板：证据问答、多文对比、查询扩展、段落翻译、引用修复、Idea 判定、领域综述、图注生成），每个模板带版本号。这一设计既是工程规范，也直接服务于决赛答辩要求的“Prompt 审计记录”。

4.9 性能优化策略

问题	现象	措施	效果
重排过慢	12 候选×整块文本，单次 5.1s	输入截断 600 字 + 多线程 + 候选池调优	5.1s → 1.58s
Idea 考古耗时	37 条陈述各做一次检索	同上 + 批量向量化	11m43s → 85s

问题	现象	措施	效果
综述接口	首次 88s，评审无法等待	按库指纹磁盘缓存	88s → 0.03s
长文档索引	全书稠密索引阻塞可用性	BM25 秒级先可用、稠密异步补齐	冷启动可用

其中“截断到 600 字”是实测下限：截断到 400 字会砍掉关键句（“8 NVIDIA P100 GPUs”恰落在 400 字之外），导致检索失败。这类阈值必须靠测试确定，不能凭直觉。

5　核心功能实现

5.1　模块一：解析与语义去重

- 字符级行重建、双栏判定、通栏分隔带、标题树（字号聚类 + 编号交叉验证）。
- 表格经 find_tables 抽取并转 Markdown；公式与引用标记保留原文。
- 扫描件按页判定后走 RapidOCR；公式区域不强识别，避免乱码污染答案。
- 语义去重：arXiv 基号 + 标题归一 + 正文 SimHash，多版本合并为同一作品节点。

5.2　模块二：抗幻觉问答

- 章节感知分块（不跨节），保留块级 bbox 并集与块内逐段 bbox。
- 证据按 [E 编号] 注入提示词，回答中的标记由服务端校验，通过后转为可点击锚点。
- 拒答输出包含原因与相关度数值，便于用户判断是“库里没有”还是“问得不对”。

5.3　模块三：版式阅读与双语联动

前端以 PDF.js 渲染原版式，叠加 bbox 高亮层。坐标系需转换：PyMuPDF 使用左上原点、y 向下，而 PDF.js 的 convertToViewportRectangle 使用左下原点、y 向上，因此每个框需执行 [x0, H-y1, x1, H-y0] 翻转，否则高亮会上下颠倒。

双语联动不使用滚动比例同步（长文档必然漂移），而采用锚点对齐：PDF 侧上报（页号，页内比例），侧栏据此定位该页第 k 段；反向由顶部段落的页号与序号反算比例驱动 PDF。两方向共用一把 700ms 方向锁，避免互相驱动导致的抖动。

5.4　模块四：检索追踪与推荐

```
score = 0.60 × 语义相近度（与库质心） + 0.25 × 可复现性 + 0.15 × 方向偏好
```

相关性使用“库质心”而非单篇最相似：用户读了十余篇后，研究方向是这些文献的共同偏置。可复现性单独成项，因为无实现的新方法对科研用户价值更低，这一差异必须在排序中显式体现。点赞仅调整方向偏好而非相关性，避免推荐退化为回音室。

5.5　模块五：图谱与综述

- 参考文献实体消解（标题包含匹配 + 相似度兜底），构建有向引文网络。
- PageRank、跨代引用率、桥接度（betweenness）、边缘衍生度四项指标。
- Louvain 社区发现驱动自动综述；每篇综述附带证据块与页码。
- Idea 考古输出“仍值得探索”清单，每条带原文出处与证据分。

5.6　模块六：写作辅助与可视化

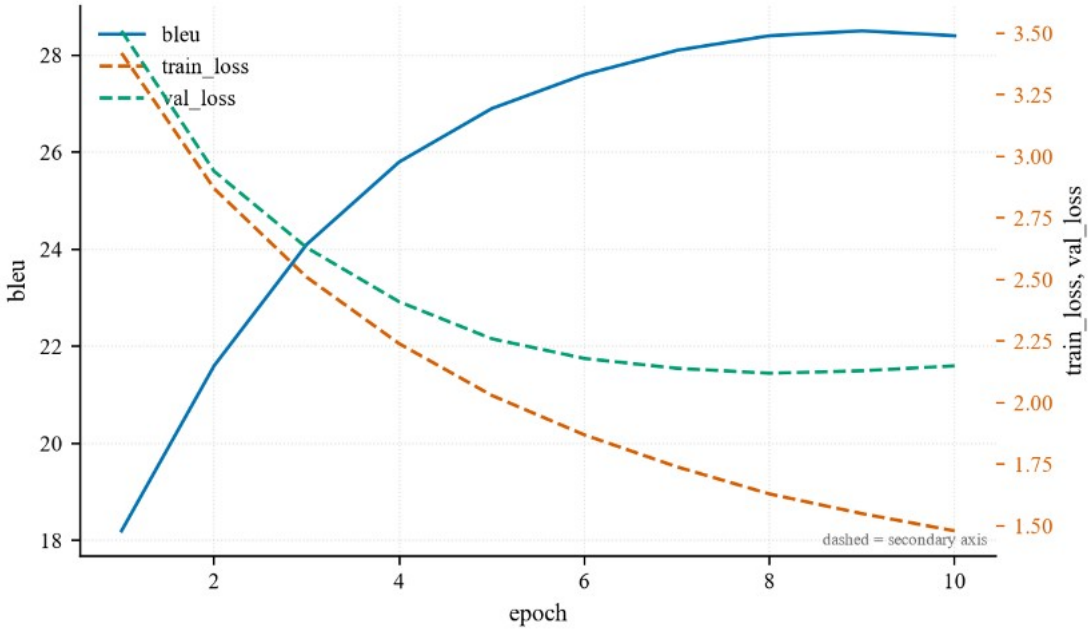


图 5-1　系统自动生成的训练曲线图（双轴处理量纲差异）

图表模块解决两个“能跑通但结果无用”的问题。其一是量纲混轴：BLEU（18–28）与损失（1.5–3.5）同轴绘制会把损失压成平线，趋势信息完全丢失，系统据量级比（≥3）自动分副轴。其二是雷达图语义：应“每行一个多边形”以对比对象，而非把各列压成一条均值线。

图注只使用真实统计量（峰值位置、首末变化率），不使用“该图展示了…”式空话；同时输出可复现绘图脚本与 TikZ/pgfplots 源码。

6 测试与部署

6.1 验收体系

全部能力以可执行断言呈现，一条命令输出模块级报告，不依赖人工点击与演示视频：

```
.venv/Scripts/python.exe scripts/verify_all.py
```

模块	检查项	结果
模块一	解析质量（双栏/标题树/参考文献/锚点）	通过
模块二	跨语言检索（中文问英文细粒度事实）	通过
模块二	抗幻觉 Guardrails（编号/闸门/拒答）	通过
闭环	服务层接口（健康/检索/问答/SSE/图表）	通过
模块五	引用图谱（版本合并/基石榜/关键边/社区）	通过
模块五	Idea 考古与自动综述（时间约束/保守判定）	通过
模块六	数据可视化（选型/分轴/图注/脚本）	通过
模块四	论文发现（去重/可复现性/反馈/BibTeX）	通过
交付	认证与评审账号（登录/Cookie/Bearer/篡改）	通过

6.2 实测数据摘要

指标	数值
语料规模	18 篇 PDF（含官方测试集 v1/v7）
索引规模	892 个内容块，384 维稠密向量
解析结果（v1）	25 标题 / 19 章节 / 41 参考文献 / 54 引用
中文检索命中率	6/6（全部 top-3）
抗幻觉断言	23/23 通过
引用图谱	16 节点 / 42 边 / 4 社区
Idea 考古	37 条陈述 / 19 类 / 6 条待探索
交互检索耗时	约 1.6 秒/次（含重排）

6.3 部署

- Docker Compose：api（含健康检查）+ web（多阶段构建），模型缓存挂卷。
- 本地：scripts/start.ps1 一键启动前后端。
- 配置：.env.example 提供全部变量；密钥仅经环境变量注入，不入仓库。
- 账号：reviewer / review2026（评审）、demo / demo2026（演示），可经变量覆盖。

6.4 已知限制（如实声明）

限制	影响	说明
未配置模型时降级	翻译/对比/综述叙述化减弱	系统显式标注，不伪造结果
参考文献实体消解	个别缺号导致少边	v1 的 37/38 号条目跨栏合并所致
图谱为库内局域图	规模受限于本地文献	可接 OpenAlex 外部边扩展
Docker 镜像未做镜像级验证	部署存不确定性	开发机无 Docker，依赖组合已在虚拟环境实测

限制	影响	说明
认证为演示级	不适用于高安全场景	密码存环境变量，无哈希/锁定/轮换

7 创新点说明

7.1 技术创新

编号	创新点	与现有做法的差异
T1	三道抗幻觉闸门	把“抗幻觉”从提示词技巧变为服务端可验证的工程约束，其中相关性闸门解决了“格式合法但答非所问”
T2	字符级版面重建	绕开 PyMuPDF 跨栏粘行这一库级限制，使双栏判定与阅读序在真实 PDF 上可用
T3	量级感知的分轴策略	自动识别序列量级差异并分副轴，避免信息被压平
T4	时间衰减基石度量（有界乘数）	用跨代引用率替代经验衰减因子，无自由参数、可做敏感性分析
T5	Idea 考古的保守判定	按可用能力分级，无模型时不下“已解决”结论，规避最有害的误判
T6	锚点对齐的双语联动	以共享段落锚点替代滚动比例映射，消除长文档双语漂移

7.2 应用创新

编号	创新点	用户价值
A1	引用深链：问答卡片一键跳原文并高亮	把“可溯源”从概念变成可操作的动作
A2	可复现性加权推荐	把“有没有代码”作为显式排序因子，而非附带信息
A3	可复现绘图脚本随图输出	评审/合作者可拿同一份 CSV 重画，核验成本趋近于零
A4	零运维单机交付	无需 GPU、无需外部向量库，评审一条命令即可完整复现

8 总结与展望

本作品完成了一个覆盖科研全流程的助手 Agent，并在“抗幻觉”这一科研场景最关键的维度上，给出了可验证的工程答案。开发过程中的若干次自我纠错——误判单双栏、基石公式方向错误、Idea 判定过于自信、图表量纲混轴——都被记录为架构决策文档，构成作品在“学术严谨性”上的真实证据。

后续可沿三个方向深化：

- 外部引文图谱：接入 OpenAlex 补全库外引用关系，把 16 篇局域图扩展为领域全景图。
- 多模态理解：引入视觉模型解析图表与公式图片，替代当前的占位策略。
- 协同与版本：支持团队共享文献库与批注，形成可积累的科研知识资产。

附录 A 架构决策记录索引

编号	主题	结论
ADR-0001	中文查询检索英文论文	增加查询扩展层，扩展只影响召回不影响排序
ADR-0002	分栏与阅读序	字符级重建，不用 block/line 级处理
ADR-0003	基石论文度量	有界乘数替代经验衰减因子，无自由参数
ADR-0004	Idea 考古判定	按能力分级，无模型时不下“已解决”结论

附录 B　提示词模板清单

模板	用途	版本
grounded_answer	抗幻觉证据问答	1.1.0
cross_paper_compare	跨论文对比表格	1.0.0
query_expand	中文查询扩展	1.0.0
translate_paragraph	段落学术翻译	1.0.0
citation_repair	无标记回答重写	1.0.0
future_judge	Idea 是否已解决判定	1.0.0
area_review	聚类综述生成	1.0.0
figure_caption	学术图注生成	1.0.0

附录 C　主要接口清单

方法	路径	说明
GET	/api/health	健康检查（公开）
POST	/api/login	登录并下发会话 Cookie
GET	/api/papers	文献库列表
POST	/api/papers	上传 PDF 并解析入库
POST	/api/ask	抗幻觉问答（含锚点）
POST	/api/ask/stream	SSE 流式问答
GET	/api/papers/{id}/outline	标题树
GET	/api/papers/{id}/paragraphs	段落级正文与坐标
POST	/api/translate	段落翻译（带缓存）
POST	/api/charts	CSV 生成学术图表
GET	/api/discover	arXiv 检索与推荐
GET	/api/graph	引用图谱数据
GET	/api/graph/review	自动综述与 Idea 考古